ANÁLISE DE DADOS (16682) · MINI-PROJETO EM AULA · MÓDULOS 2 A 7

Quem vai subscrever o depósito?

Da exploração à seleção de variáveis, em duas horas, com dados reais de um banco português

Duração	Trabalho	Entrega	Cotação
2 horas (esta aula)	Em pares	Notebook `.ipynb` no Moodle, até ao fim da aula	20 valores

1. O cenário

Entre 2008 e 2010, um banco português fez várias campanhas de telemarketing para vender depósitos a prazo. Cada linha do ficheiro é um cliente contactado: quem era, como foi contactado, o que aconteceu em campanhas anteriores e como estava a economia nessa altura. A última coluna diz se aceitou ou não.

A equipa de marketing quer gastar menos em chamadas inúteis e fez-vos uma pergunta simples: **que informação vale mesmo a pena recolher para saber quem vai dizer que sim?** Não vos pedem o melhor modelo possível. Pedem dados bem preparados e uma lista curta de variáveis que consigam defender perante alguém que nunca ouviu falar de AUC.

2. Os dados

O ficheiro `bank-additional-full.csv` está no Moodle, junto com o notebook base `MP-SelecaoVariaveis-Aluno.ipynb`. Coloquem os dois na mesma pasta. O separador é `;`. São 41 188 linhas e 21 colunas.

Grupo	Variáveis
Cliente	`age`, `job`, `marital`, `education`, `default` (crédito em incumprimento), `housing` (crédito habitação), `loan` (crédito pessoal)
Último contacto	`contact` (telemóvel ou fixo), `month`, `day_of_week`, `duration` (duração da chamada, em segundos)
Campanhas	`campaign` (n.º de contactos nesta campanha), `pdays` (dias desde o último contacto numa campanha anterior), `previous` (contactos antes desta campanha), `poutcome` (resultado da campanha anterior)
Economia	`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `euribor3m`, `nr.employed`
Alvo	`y`: subscreveu o depósito? (`yes` / `no`)

Fonte: Moro, S., Rita, P. & Cortez, P. (2014). Bank Marketing [Dataset]. UCI Machine Learning Repository, https://doi.org/10.24432/C5K306 (licença CC BY 4.0).

> **Atenção**
> Estes dados têm armadilhas. Não estão todas assinaladas, e encontrá-las faz parte do trabalho. Uma pista: se `df.isnull().sum()` vos disser que está tudo perfeito, desconfiem.

3. Plano da aula

Tempo	Parte	Módulos	Cotação
0–20 min	A · Conhecer os dados	2, 5, 6	3 valores
20–45 min	B · Qualidade dos dados	2, 6	5 valores
45–60 min	C · Redundância	4, 6	3 valores
60–105 min	D · Seleção de variáveis	7	7 valores
105–120 min	E · Conclusão e entrega	—	2 valores

A parte D é a que vale mais. Se aos 60 minutos ainda estiverem na parte B, passem para a D e voltem atrás se sobrar tempo.

4. Tarefas

Regra geral: cada decisão (apagar, transformar, manter, excluir) leva **uma ou duas frases a explicar porquê**, numa célula Markdown logo a seguir ao código. Código sem justificação vale metade.

Parte A — Conhecer os dados *≈ 20 min*

A1 Classifiquem cada variável: numérica, categórica nominal ou categórica ordinal. Há pelo menos uma que parece numérica e não se comporta como tal. **[1,0]**

A2 Calculem a proporção de `yes` e `no`. Expliquem, numa frase, o que isto implica para a escolha da métrica de avaliação. **[1,0]**

A3 Três gráficos, cada um com a pergunta escrita por cima e a resposta por baixo. Sugestões: taxa de `yes` por `poutcome`, taxa de `yes` por `month`, boxplot de `campaign`. **[1,0]**

Parte B — Qualidade dos dados *≈ 25 min*

B1 Há linhas duplicadas? Quantas? O que fazem com elas? **[0,5]**

B2 Encontrem os valores em falta que não aparecem como `NaN`. Façam uma tabela com contagem e percentagem por variável. Para `default`, verifiquem se a taxa de `yes` muda entre quem tem o valor em falta e quem não tem, e decidam: categoria própria, imputação ou remoção? **[1,5]**

B3 Olhem com atenção para `pdays`. O que significa o valor mais frequente? Transformem a variável em algo que faça sentido e comparem o resultado com `poutcome`. **[1,0]**

B4 Apliquem a regra do IQR a `age`, `campaign` e `previous`. Os valores extremos são erros ou casos reais? O que acontece com `previous`, e porquê? **[1,0]**

B5 Calculem a AUC de `duration` sozinha como preditor do alvo. O valor é bom demais? Pensem em quando é que esta informação fica disponível e decidam o que fazer com ela. **[1,0]**

Parte C — Redundância *≈ 15 min*

C1 Matriz de correlação das cinco variáveis económicas, com mapa de calor. Usando um limiar de $|r| > 0{,}8$, que variáveis são redundantes? Qual guardariam? **[1,5]**

C2 Apliquem PCA às mesmas cinco variáveis, depois de padronizadas. Quanta variância explica a 1.ª componente? Quantas componentes são precisas para 95 %? O que diz isto sobre o bloco económico? **[1,5]**

Parte D — Seleção de variáveis *≈ 45 min*

D1 Divisão treino/teste 75/25, estratificada por `y`, com `random_state=SEED`. A partir daqui o conjunto de teste só se usa uma vez, em D5. **[0,5]**

D2 Montem um `ColumnTransformer` (padronização das numéricas, one-hot das categóricas) e um modelo de referência: regressão logística com todas as variáveis, AUC em validação cruzada estratificada de 5 folds, só no treino. Quantas colunas existem depois da codificação? **[1,5]**

D3 **Filtro.** `SelectKBest` com `f_classif` (k = 10) dentro do `Pipeline`. AUC em validação cruzada e lista das colunas escolhidas. **[1,5]**

D4 **Embedded.** `SelectFromModel` com uma regressão logística com penalização L1, dentro do `Pipeline`. Experimentem 2 ou 3 valores de `C` e escolham um. AUC em validação cruzada e lista das colunas escolhidas. **[1,5]**

D5 Tabela com número de colunas e AUC de cada abordagem, e a interseção das variáveis escolhidas por D3 e D4. Avaliem as três no teste, uma única vez. Os dois métodos discordam? Olhem para as variáveis económicas e para `contact` e expliquem a diferença com o que viram na parte C. **[2,0]**

Parte E — Conclusão *≈ 10 min*

E1 Um parágrafo de 8 a 12 linhas, sem jargão, para a equipa de marketing: que informação vale a pena recolher, o que pode ficar de lado e quanto se perde (ou não) com isso. **[2,0]**

5. Ajudas de código

Não precisam de memorizar isto. Precisam de perceber o que cada linha faz.

```
df = df.replace('unknown', np.nan)
SimpleImputer(strategy='constant', fill_value='desconhecido')
Pipeline([('pre',      pre),      ('sel',      SelectKBest(f_classif,      k=10)),      ('lr',
LogisticRegression(max_iter=2000))])
SelectFromModel(LogisticRegression(l1_ratio=1, solver='liblinear', C=0.01))
pipe.fit(Xtr, ytr); pipe[:-1].get_feature_names_out()   # colunas que sobreviveram
```

> **Lembrete do Módulo 7**
>
> Escalonamento, imputação e seleção ficam **dentro** do `Pipeline`. Se fizerem `SelectKBest(...).fit(X, y)` sobre os dados todos antes de dividir, o teste deixa de ser um teste. Usem um objeto novo de `LogisticRegression` em cada pipeline (ou `clone()`): partilhar o mesmo objeto entre pipelines dá erros difíceis de perceber.

6. Entrega e regras

- Submetam no Moodle o notebook `.ipynb` com os nomes e números dos dois elementos na primeira célula, até ao fim da aula. Antes de submeter: Kernel → Restart & Run All. Tem de correr do início ao fim sem erros.
- Uso de IA generativa: permitido como apoio, desde que declarado numa célula no fim do notebook (para quê e em que partes). Os dois elementos têm de conseguir explicar qualquer célula.
- Penalizações: `duration` usada nos modelos da parte D sem discussão, −1 valor. Seleção ou escalonamento feitos fora do `Pipeline` sobre os dados todos, D3 e D4 valem no máximo metade. Notebook que não corre, −2 valores.